


Relatório 1 - O que são dados sintéticos? (I)

Felipe Fonseca

Descrição da atividade

Esse card teve como objetivo introduzir o que são dados sintético. Primeiramente com um vídeo e depois com a leitura de um blog.




O vídeo inicia justamente com a definição de dado sintético, que é um dado “fake”, mas criado para parecer real, e substituir o dado real em um modelo de machine learning. Os dados sintéticos são importantes justamente para evitar essa necessidade de sempre ter grandes volumes de dados reais o tempo inteiro para treinar modelos, o que é difícil principalmente em casos que requerem privacidade, como em um modelo para identificar emoções por análise facial, ou então laudos médicos e coisa do tipo. Por isso, os dados sintéticos são criados a partir de dados reais, com o objetivo de parecerem reais também. O uso não se limita apenas a substituição dos dados reais, mas também na criação de mais dados em casos de dados desbalanceados, ou seja, em um modelo binário por exemplo, onde os dados cuja resposta é “sim” são bem maiores que os dados cuja resposta é “não”, uma solução é a criação de dados sintéticos cuja a resposta será não, para que assim o modelo fique balanceado e consiga cumprir seu objetivo. Apesar disso, os dados sintéticos não eliminam a necessidade dos dados reais, apenas diminui a quantidade necessária.

A segunda parte foi a leitura do blog, que continha muitos exemplos de uso do dado sintético. Dentre os conceitos mais importantes, foram citados por exemplo a similaridade de dados aumentados e dados anonimizados e dados sintéticos, citando por exemplo que ao utilizar as 2 técnicas é possível criar um dado sintético. Também foi citado a importância financeira do dado sintético, mostrando exemplos de como um dado sintético pode ser até 100x mais barato de se obter do que um dado real, além da capacidade dos dados sintéticos de cobrir além de casos raros, casos perigosos, que seriam difíceis de capturar. Como um exemplo, irei citar o caso de situações de riscos para treinamento de carros autônomos, onde seria muito difícil pegar dados reais de situações com esse risco, e nesses casos, dados sintéticos são fundamentais.


O blog também cita um ponto de “como são criados os dados sintéticos”, tendo citado técnicas como VAEs e GANs, além de motores de renderização 3d.

Variational Autoencoders



VAE (Variational autoencoders) é uma técnica de deep learning que pode ser resumida a utilizar um encoder para pegar as características principais de um dado, o que faz o dado ser o que ele é, e depois aplicar uma variância no espaço latente e aplicar isso encima de um decoder, fazendo com que invés do dado voltar exatamente ao que era, ele voltar como algo diferente, mas ainda tendo as características importantes do dado.

Generative Adversarial Networks



Já GANs (generative adversarial networks) é uma técnica também de deep learning que tem como base um gerador e um discriminador, que são treinados quase que simultaneamente, mas com o objetivo de combater um ao outro: o discriminador tenta

descobrir quais imagens são reais e quais foram geradas, e o gerador tenta criar imagens que pareçam reais para enganar o discriminador.

Já os motores de render são ferramentas que permitem criar objetos 3d para treinar modelos de IA. Dentre as ferramentas mais famosas, tem o omniverse da própria Nvidia, que foi citado no blog, mas também tem o Blender, a Unreal Engine, e a Unity.

Dificuldades

Sem dificuldades.

Conclusões

A principal conclusão sobre os dados sintéticos é de que, apesar de ser um dado “Falso”, pois pela definição ele não é real, ele possui tantas características reais, e possui tantas informações que parecem reais ou simulam a realidade, que dentro do machine learning ele não recebe a classificação de falso, e sim de sintético, é algo gerado artificialmente mas que funciona tão bem ou podendo ser até melhor que o dado real, para o treinamento do modelo designado, e é uma técnica fundamental para diminuir custos e poder balancear datasets.

Referencias

Fontes do Card:

[What is Synthetic Data? No, It's Not "Fake" Data – IBM Technology](#)

[O que são Dados Sintéticos? – Nvidia](#)

Fontes extras:

[O que é um autcodificador variacional? – IBM](#)

[O que é GAN \(generative adversarial networks\)? - IBM](#)