


Relatório 4 - Domain gap (I)

Felipe Fonseca

Descrição da atividade



O primeiro artigo que eu li (Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World) tem como foco treinar uma rede neural profunda utilizando apenas dados sintéticos feitos em uma simulação, sem nenhum tipo de pré-treinamento com dados reais. O foco é no Domain Gap, em treinar o modelo em vários ambientes diferentes utilizando fatores de aleatoriedade.

Inicialmente é buscado no artigo quais métodos poderiam ser utilizados, ou quais métodos já foram utilizados e testados anteriormente. Dentro os principais citados, os mais interessantes são: Reconstrução 3D, Fotorrealismo e adaptação do cenário real. Porém todos esses 3 métodos tinham grandes problemas. A reconstrução 3D exigia múltiplos sensores complexos, o que levava tempo e era muito custoso. Fotorrealismo era semelhante, era custoso, leva muito tempo para renderizar, e os resultados ficam muito limitados para que os robôs utilizassem. Já a adaptação de um cenário real exigiria dados adicionais e processos de retreinamento para que o ambiente simulado se adaptasse e representasse o ambiente real.

O foco do artigo é na nova abordagem adotada por eles, que tem foco na rapidez e não no realismo, ou seja, invés de gastar dinheiro e tempo tentando deixar os ambientes simulados extremamente realistas e parecidos com a vida real, eles usavam iluminações aleatórias, e várias texturas e cores não realistas fazendo com que o modelo fosse obrigado a focar na forma e na essência do objeto.

Agora em relação aos métodos utilizados, de entrada, o modelo iria receber uma imagem comum, e retornar a previsão das coordenadas x y e z dos objetos de interesse em cima da mesa. Objetos e cenários foram colocados de forma aleatória na simulação, além de colocarem iluminação aleatória e ruído na imagem.

A acurácia em relação ao mundo real foi um erro médio de 1,5cm.

Outro ponto importante que foi citado no artigo, é que a aleatoriedade das texturas é muito importante, e em cenários menores, ou seja, em datasets menores, pode ser até mais importante que a aleatoriedade da posição dos objetos.




Imagem retirada do artigo

Essa imagem representa o valor médio de erro em relação a quantidade de texturas utilizadas para gerar os cenários aleatórios.

Os principais resultados e conclusões que podem ser tirados desse artigo é que a técnica de utilizar imagens simuladas de baixa qualidade para treinar os modelos funciona, focando realmente na velocidade da geração dos dados e no baixo custo, além de que é possível treinar o modelo apenas com dados sintéticos, sem nenhum pré-treinamento com dados reais.

Indo agora para o segundo artigo (Training Deep Networks with Synthetic Data: Bridging the Reality Gap by Domain Randomization), esse busca utilizar dados sintéticos para reconhecimento de carros.

Focando na randomização, uma técnica diferente que foi utilizada nesse artigo foi a de flying distractors, que são formas geométricas que aparecem “voando” de forma aleatória na imagem. O objetivo é que a rede neural aprenda a ignorar objetos que não são o foco da rede neural, independentemente da qualidade dos mesmos na imagem.

Quanto a variedade de objetos randomizados, foram selecionados 36 modelos 3D de carros genéricos, diferentes texturas, imagens para background, localizações de câmera, ângulos de câmera, pontos de luz e visibilidade do chão plano. Tudo isso foi feito de forma aleatória para que cada imagem seja diferente da outra.

Para validar o dataset, fizeram o treinamento de uma rede neural utilizando 3 datasets:

- O dataset sintético feito no artigo;
- Dataset KITTI (imagens reais);
- Dataset VKITTI (imagens sintéticas mas que se assemelham muito ao dataset KITTI original);

Comparando puramente os datasets já foi possível obter uma conclusão: o dataset sintético gerado no artigo possui dados mais distribuídos do que os outros 2. Isso é possível ser analisado a partir das imagens de comparação utilizadas no próprio artigo, que demonstra que a partir do dataset sintético é possível ter mais carros por imagem, e principalmente, ter mais carros em diferentes coordenadas na imagem:





Imagem retirada do artigo

Estatísticas do KITTI é a de cima, do VKITTI é a do meio, e do dataset sintético é a de baixo.

No treinamento da rede neural com o dataset sintético, foram aplicados três data augmentations: brilho aleatório, contraste aleatório e um ruído baseado na distribuição normal. Mas o principal ponto disso foi o teste que eles fizeram: quando a iluminação foi randomizada, mas o brilho e contraste foi desligado (sem data augmentation), a acurácia da validação quase não caiu, mas quando desativaram a iluminação do data augmentation, ou seja, ficou com uma luz fixa, a acurácia da validação caiu significativamente. A conclusão desse trecho é que manter diferentes luzes, ou seja, diferentes pontos de luzes, fazendo com que as sombras também sejam geradas em diferentes lugares, é essencial para um dataset sintético.

Outra coisa que fez diferença foi o teste de remover os flying distractors: fez o modelo perder 1.1% de acurácia, o que também é um valor significativo nesse contexto.

Os autores também criaram um gráfico mostrando todas as remoções que eles foram fazendo para testar os resultados do modelo:



Retirado do artigo

A principal conclusão retirada desse artigo são as diferentes randomizações que podem ser feitas na geração do dataset sintético que influenciam diretamente no resultado positivo de um modelo de visão computacional.

No último artigo (Synthetic-to-Real Domain Adaptation for Object Instance Segmentation), o objetivo desse artigo é bem diferente dos outros, pois ele não cria um dataset sintético, ele adapta eles. O objetivo é adaptar o dataset sintético de forma que quando o modelo seja testado em dados reais, ele ainda tenha o mesmo desempenho.

A ideia central que fez o artigo funcionar foi um funcionamento inspirado nas GANs, redes neurais adversárias, onde uma tenta enganar a outra. O funcionamento no artigo especificamente foi feito por módulos. O primeiro módulo buscava aproximar os dados sintéticos dos dados reais através de características mais gerais das imagens, como iluminação, textura e estilo geral da cena). Vale ressaltar que a rede neural que gerava as imagens não sabia como as imagens reais eram, quem sabia é apenas o discriminador, que tentava achar quais eram as imagens reais e as imagens sintéticas. O segundo módulo tinha objetivos a nível de objeto, diminuindo e aumentando o objeto na cena, rotacionando etc. O terceiro módulo atuava a nível de máscara, lidando com contornos por exemplo.

Os resultados trazidos desse artigo foram promissores pois obteve acurácia maior que todos os trabalhos anteriores que haviam sido utilizados como referências. A principal conclusão desse artigo específico é que a criação dos dados sintéticos pode não ser o fim do trabalho, e é necessário adapta-los depois caso não haja um desempenho bom quando testado em dados reais.

Conclusões

Nesse card foram abordados três artigos que lidam com o domain gap de formas diferentes. Os dois primeiros usam domain randomization, ou seja, invés de tentar deixar a simulação realista, usam texturas e iluminações aleatórias pra forçar o modelo a aprender a essência do objeto. Já o terceiro artigo não cria o dataset sintético, ele adapta um já pronto pra se aproximar dos dados reais, usando uma lógica parecida com GANs. De forma geral, essas técnicas não são rivais, dá pra usar domain randomization pra gerar o dataset sintético e depois ainda adaptar o modelo com poucos dados reais, o que mostra um caminho prático pra reduzir custo sem perder muito desempenho.

Referencias

TOBIN, J. et al. Domain randomization for transferring deep neural networks from simulation to the real world. IROS, 2017.

TREMBLAY, J. et al. Training deep networks with synthetic data: bridging the reality gap by domain randomization. CVPRW, 2018.

ZHANG, H. et al. Synthetic-to-real domain adaptation for object instance segmentation. IJCNN, 2019.